

Εθνικό Μετσόβιο Πολυτεχνείο

Επιστήμη Δεδομένων και Μηχανική Μάθηση

Εξαμηνιαία Εργασία

Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Όνομα / Α.Μ

Νικόλαος Αναστασίου / 03400283

Αθήνα, 25 Μαΐου 2026

Περιεχόμενα

Εισαγωγή	2
Ζητούμενο 1	2
Ζητούμενο 2	3

Εισαγωγή

Στη παρούσα εργασία υλοποιήθηκαν τα Ζητήματα 1 έως 6 σε περιβάλλον Apache Spark και Apache Hadoop, ενώ ο κώδικας για την απάντηση των Queries γράφτηκε σε Python ακολουθώντας τα templates που μας δόθηκαν.

Η υλοποίηση έγινε τόσο σε τοπικό επίπεδο για την ανάπτυξη του κώδικα αλλά και στο απομακρυσμένο cluster που μας δόθηκε πρόσβαση μέσω VPN. Η ανάπτυξη έγινε σύμφωνα με τον οδηγό του github.com/ikons/bigdata-dsml.

Αντί να γίνει εγκατάσταση του Spark και του Hadoop στο WSL των Windows έγινε σε native Ubuntu 24.04.4 LTS καθώς αντί για Windows έχω Linux. Η μόνη διαφορά είναι η έκδοσή της Java που αντί για Java OpenJDK 11 που ήταν η προτεινόμενη χρησιμοποιήθηκε η προ εγκατεστημένη δηλαδή η Java OpenJDK 21.

Ζητούμενο 1

Τα δεδομένα που δόθηκαν για την εργασία είναι σε μορφή .csv η οποία αν και είναι εύκολη στη διαχείριση της και μπορεί να διαβαστεί ανοίγοντας το αρχείο με έναν text editor δεν είναι η βέλτιστη για την υποδομή του Spark. Για τον λόγο αυτό τα δεδομένα μετατράπηκαν στην προτεινόμενη μορφή για Spark που είναι η Parquet.

Υπάρχουν πολλές μορφές δεδομένων οι οποίες είναι καταλληλότερες για Spark έναντι του απλού .csv, αρχικά είναι η μορφή .parquet, στην οποία θα μετατραπούν τα δεδομένα της εργασίας, η οποία είναι Columnar δηλαδή αποθηκεύει τα δεδομένα ανα στήλη και όχι ανα γραμμή. Έτσι αμα ένα query ζητάει μόνο 1 στήλη από τις 10 τότε από τον δίσκο διαβάζεται μονό αυτή η μια στήλη, και με αυτό τον τρόπο πετυχαίνει μεγαλύτερες ταχύτητες read, καλύτερη συμπίεση δεδομένων, υποστηρίζει επίσης αλλαγές στη δομή των δεδομένων και Predicate Pushdown το οποίο παραλήπτει δεδομένα που δεν χρειάζονται κατά την εκτέλεση ενός query αυξάνοντας έτσι ακόμη περισσότερο την ταχύτητα εκτέλεσης.

Ακόμη ένα format κατάλληλο για Spark είναι το ORC (Optimized Row Columnar), το οποίο είναι Columnar σαν το Parquet, και έχει πολλές ομοιότητες. Αναπτύχθηκε για το Apache Hive και λειτουργεί εκεί καλύτερα από ότι στο Spark. Οι διαφορές ανάμεσα στα 2 είναι ότι: Το ORC έχει σαν μικρότερη μονάδα το Row Group ενώ το Parquet έχει ένα Page 8kb, το ORC έχει Column Pruning το οποίο προσπερνάει τα columns τα οποία δεν χρειάζονται για κάποιο query ενώ το parquet έχει column chunks τα οποία είναι ξεχωριστά αποθηκευμένα μέσα στον δίσκο. Επίσης υπάρχουν διαφορές στο φιλτράρισμα των δεδομένων καθώς στο ORC υπάρχουν φίλτρα για min/max, bloom filters και offsets ενώ στο parquet υπάρχουν αντίστοιχα για file, chunk και page.

Ζητούμενο 2

Στο ζητούμενο 2 θα δημιουργηθούν 3 υλοποιήσεις για το ίδιο Query όπου στην πρώτη θα χρησιμοποιεί μονό DataFrame χωρίς User Defined Function (UDF), έπειτα θα υλοποιηθεί ξανά με UDF και τέλος θα γίνει μια υλοποίηση με Resilient Distributed Dataset (RDD). Για όλα τα υπο ερωτήματα τα Crime Data συγχωνευτήκαν σε ένα ενιαίο αρχείο .csv και .parquet για την ευκολότερη διαχείριση τους.